

TECHNICAL PAPER · VERSION 4

TDT-v4 : 離散状態遷移に基づく 前進評価型3値学習フレームワーク

ネイティブ3値モデルのためのイベント駆動型・離散ゼロ次最適化

Ternary Dynamics Theory: A Forward-Only, Event-Driven Framework for Discrete Zeroth-Order
Optimization

2026年9月

要旨

本稿は、重みの離散成分を学習開始時から $\{-1, 0, +1\}$ に制約したネイティブ3値モデルを、有限状態グラフ上の離散行動選択として学習する Ternary Dynamics Theory (TDT) の検証可能な枠組みを提示する。提案学習則 TDT-D は、候補状態対に対する2回的前進評価から得たスカラー損失差を、辺ごとの正規化3値票へ変換し、有限精度の edge evidence accumulator に時間積分して隣接遷移を発火させる。潜在浮動小数点重みと誤差逆伝播を必須としない一方、1個のスカラー測定から高次元の離散行動価値を復元するには、局所遷移場の低実効次元性、疎性、低ランク性、またはブロック相関などの構造が必要である。本稿は、初通過誤率を biased gambler's ruin により厳密化し、符号一致率を離散行動正解率と局所regretへ置換する。さらに、境界カウンタロック、票の陳腐化、離散摂動の相互作用残差、複数摂動数 M の計算費、カウンタのHBM帯域、および共通seedとscalar all-reduceを用いる分散プロトコルを定式化する。提示する命題は明示的条件下の有限時間評価に限定され、大域収束や総学習コスト削減を主張しない。主要な反証可能指標は、離散行動正解率、発火後損失変化、局所regret、相互作用比、同一到達lossまでのforward-equivalent、J/token、HBM bytes/tokenである。

キーワード：ネイティブ3値学習、離散ゼロ次最適化、離散行動選択、初通過過程、イベント駆動学習、BigTernary

1. はじめに

低ビットLLM研究は、重みや活性化の表現を圧縮し、主として推論時のメモリ、帯域、演算量を下げてきた。BitNet b1.58 は3値重みを学習開始時から用いるモデルクラスを示したが、代表的な学習法は高精度の勾配、straight-through estimator (STE)、および高精度オプティマイザ状態をなお利用する [1-3]。したがって、前向き計算が3値であることと、事前学習そのものが低コストであることは同値ではない。

本稿の対象は、学習後モデルの変換や推論専用量子化ではなく、離散重みを最初から直接更新するネイティブ3値学習である。TDT-D は BigTernary、すなわち巨大3値モデルの学習時コストを下げる研究軸に属する。3値重みに適した深さ・幅・残差構造を探索する DeepTernary とは評価軸を分離し、アーキテクチャ上の利点を学習コスト削減の証拠として扱わない。

本稿の第一の貢献は、TDT-Dを符号推定ではなく離散行動選択として定義し、正解率だけでなく損失差を重み付けした局所regretを導入することである。第二に、境界で不可能方向の証拠が蓄積する問題を避けるため、parameter counter を有向辺の evidence accumulator へ置き換える。第三に、初通過誤率を単純な iid 3値票について厳密に導き、閾値と平均待ち時間を gambler's ruin と停止時刻から評価する。第四に、2点測定の識別可能性を局所遷移場の実効次元仮説として明示し、離散摂動固有の相互作用残差を測定対象にする。第五に、計算、メモリ帯域、エネルギー、通信を同一到達lossで評価する段階的実験計画を提示する。

主張の範囲

TDT-Dは完成済みの収束理論ではなく、検証可能な離散ゼロ次最適化フレームワークである。本稿で証明するのは限定された確率過程と明示的ドリフト条件に関する命題であり、巨大モデルでの精度、スケール、総コスト優位はすべて実験仮説である。

2. 関連研究と位置づけ

BitNet b1.58 は3値重みを持つTransformerをスクラッチから学習し、同規模の高精度モデルに対する競争的性能を報告した [1]。BitNet a4.8 と BitNet v2 は活性化の低ビット化を進め、外れ値処理やHadamard変換を導入している [2,3]。これらはネイティブ3値モデルの実現可能性を支えるが、TDT-Dの前進評価のみの直接更新を保証しない。

Bop は二値ネットワークにおける潜在重みを慣性として再解釈し、直接的な重み反転則を提案した [4]。TernGrad は逆伝播で得た勾配を3値化して通信量を減らし [5]、WAGE は重み・活性化・勾配・誤差を低精度化した [6]。いずれも離散・低精度学習の重要な先例だが、TDT-Dとは勾配計算の有無が異なる。SPSA と MeZO は2点の関数評価に基づくゼロ次最適化の基盤を与える [7,8]。一方、TDT-Dでは摂動半径を0へ縮められず、隣接3値状態を同時に多数変更したときの非加法的相互作用が残る。

表1 関連手法との機構上の比較

手法	学習信号・状態	TDT-Dとの主な差
BitNet b1.58 / a4.8 / v2 [1-3]	3値重み、低ビット活性化、勾配ベースQAT	TDT-Dは潜在高精度重みとbackpropを必須としない
Bop [4]	backprop勾配の移動平均で二値重みを反転	直接離散更新は近いが、ゼロ次ではなく実数慣性を保持
TernGrad [5]	計算済み勾配を3値化	通信圧縮であり、勾配生成そのものは残る
WAGE [6]	整数・低精度のforward/backward	低精度学習の先例だがbackprop型
SPSA / MeZO [7,8]	2点損失差によるゼロ次更新	通常は連続パラメータ。TDT-Dは離散辺と発火則を持つ
TDT-D（本稿）	scalar差分、正規化3値票、edge evidence	離散行動選択と初通過発火を一次対象とする

3. モデル、状態空間、離散行動

3.1 3値成分と層スケール

層1の実効重みを、3値成分 T_1 と正の層スケール α_1 の積として定義する。 α_1 はパラメータ数に対して低次元の補助状態であり、3値制約の対象は T_1 である。

$$W_1 = \alpha_1 T_1, T_1 \in \{-1, 0, +1\}^{n_1}, \alpha_1 > 0$$

初期検証では α_1 を固定する。fan-inを d_1 、ゼロ率を $\pi_{0,1}$ とし、非ゼロ符号を対称に初期化する場合、単純な分散保存初期値として $\alpha_1 = g_1 / \sqrt{(d_1(1 - \pi_{0,1}))}$ を用いる。 g_1 は残差構造・活性化に応じたゲインである。後段では、固定、低頻度更新、FP16の層スカラー、または低次元ゼロ次更新を比較し、 α_1 の費用を独立に計上する。

W3/A3の意味

W3はコア線形層の T_1 が3値であること、A3は量子化スケールを伴う線形層入出力など、明示したstored activationが3値であることを指す。GEMM accumulator、RMSNorm、attention logits、softmax、residual sum、lossまで3値であることは意味しない。各演算の精度は別に明記する。

3.2 マルコフ状態と重みグラフ

定義1（状態）時刻 t の状態を次で定める。

$$x_t = (T_t, C_t, \alpha_t, S_t, r_t)$$

T_t は3値成分、 C_t は後述する辺証拠、 α_t は層スケール、 S_t は票正規化スケール、 r_t はブロック選択、乱数seed、閾値、リーク、version tagなどの内部状態である。これらを含めたときのみ、適応的スケジュール下の状態過程をマルコフ過程として扱う。各3値成分の状態グラフは $-1 \leftrightarrow 0 \leftrightarrow +1$ であり、全重み空間は P_3 の直積グラフである。

データ z に対する損失を $\ell(W; z)$ とし、最適化対象を母集団損失とする。

$$F(T, \alpha) = E_z[\ell(\alpha \cdot T; z)]$$

3.3 合法行動、最適局所行動、局所regret

座標 i の現在値を T_i とする。stayを含む合法行動集合と、その行動を適用した母集団損失差を次で定義する。

$$A_i(T_i) = \{a \in \{-1, 0, +1\} : |a - T_i| = 1\} \cup \{T_i\}$$

$$\Delta_i(a; T, \alpha) = F(T^{i \leftarrow a}, \alpha) - F(T, \alpha)$$

$$a_i^* \in \arg \min_{a \in A_i(T_i)} \Delta_i(a; T, \alpha)$$

同値な最小行動が複数あるときは正解集合として扱う。推定行動 $\hat{a}_i$ の局所regretを次で定義する。

$$R_i = \Delta_i(\hat{a}_i; T, \alpha) - \min_{a \in A_i(T_i)} \Delta_i(a; T, \alpha) \geq 0$$

これにより、 $T_i=0$ で+1と-1の双方が改善する場合にも、より良い行動を区別できる。Stage Aの中心指標は単なる符号一致率ではなく、 $P_{\text{action}}=P(\hat{a}_i \in \arg\min \Delta_i)$ 、 R_i 、および実際の発火後損失差である。

4. 境界整合な候補対とペア相関信号

4.1 状態依存候補対

ブロック B_t と共通seed u_t から、実行可能な2候補 T_t^+, T_t^- を生成する。境界では、反射、片側比較、または対象辺の除外を明示的に選ぶ。クリップ後の候補を形式的に対称と呼ばず、生成規則と採用率をログに残す。更新は常に隣接辺に限定するが、測定対が多数の隣接辺を同時に横断することは許す。

各座標には $e_{i,-}=(-1,0)$ と $e_{i,+}=(0,+1)$ の2辺を置き、低い端点から高い端点への向きを正とする。候補対が辺 e を正方向に横断すれば $\phi_e(u)=+1$ 、逆方向なら -1、横断しなければ0とする。

4.2 batch-conditioned信号と母集団信号

同一ミニバッチ z_t で2候補を評価し、スカラー損失差を得る。

$$y_t = \ell(\alpha_t \cdot T_t^+; z_t) - \ell(\alpha_t \cdot T_t^-; z_t)$$

辺 e のbatch-conditionedペア相関信号と母集団信号を分離する。

$$g_e^{\text{pair}}(T, \alpha; z) = E_u[(\ell(T^+; z) - \ell(T; z)) \phi_e(u)]$$

$$G_e^{\text{pair}}(T, \alpha) = E_{z,u}[(\ell(T^+; z) - \ell(T; z)) \phi_e(u)]$$

共通ミニバッチは2候補間のデータノイズを相殺するが、 G_e^{pair} が単一辺の真の損失差に一致することを保証しない。Stage Aのoracle actionは、票生成に使わない独立した大規模validation minibatchで F と Δ_i を近似する。同じミニバッチで票と正解ラベルを作る評価は禁止する。

4.3 不偏な正規化3値票

層またはブロックの正規化スケール $S_{l,t}>0$ を用い、 $a \in [-1,1]$ に対して $Q(a)=\text{sign}(a)$ を確率 $|a|$ 、0を確率 $1-|a|$ で返す確率丸めを定める。このとき $E[Q(a)|a]=a$ である。辺票を次で生成する。

$$s_{t,e} = -y_t \phi_e(u_t) / S_{l,t}, q_{t,e} = Q(s_{t,e}) \in \{-1, 0, +1\}$$

不偏性は元のpair signalではなく、正規化済み信号 $s_{t,e}$ に対する条件付き不偏性である。 $|s|>1$ のクリップは不偏性を失うため、clip率を記録する。 $S_{l,t}$ が変動すると、証拠は $\sum g_{t,e} / S_{l,t}$ を積分する。したがって $S_{l,t}$ をoptimizer stateに含め、初期実験ではaccumulation epoch内で固定し、epoch間のみslow-movingなrobust EMAで更新する。閾値 Θ はこの正規化証拠単位で定義する。

5. Edge evidence accumulator と離散行動発火

5.1 辺証拠による境界ロックの除去

各有向辺 e に $C_{t,e} \in \{-C, \dots, +C\}$ を持たせる。正値は高い端点、負値は低い端点を支持する。時刻 t で現在状態に接続する辺だけを更新する。

$$C_{t+1,e} = \text{clip}(\lambda C_{t,e} + q_{t,e}, -C, C), 0 < \lambda \leq 1$$

辺の符号が現在端点から反対端点への移動を支持し、 $|C_e| \geq \Theta_e$ なら発火候補とする。 $T_i=0$ では2本の辺が候補になり得るため、較正済み行動scoreが最も良い辺を選ぶ。発火後は当該座標の両辺証拠を既定値0へresetする。これにより、 $T_i=+1$ で不可能な+方向証拠が蓄積し、逆方向へ戻る票を長時間打ち消す boundary counter lock は構造的に生じない。

代償として、単純実装では最大 $2N$ 個のカウンタを要する。実装は現在状態に接続する辺だけを圧縮保持できるが、 $T_i=0$ では2辺が必要であり、索引コストを含めて測定する。1ブロック当たりの同時発火数は k 以下とし、 $k>1$ では集合更新の相互作用を別に評価する。

5.2 票の陳腐化とaccumulation epoch

pair signalは大域状態に依存するため、他座標の発火後に過去の票をそのまま使うとcounter stalenessが生じる。理論評価では、重み状態を固定したaccumulation epoch内でK個の候補対を測定し、その終了時に発火する同期版を標準とする。非同同期版では、リーク $\lambda < 1$ 、同一ブロック更新時reset、counter age上限、weight-version tag、依存ブロックresetの各方式を比較する。

$$\text{stale fraction} = 1 - (\text{現weight-versionで生成された有効票数}) / (\text{accumulator内の実効票数})$$

ログにはvote age分布、stale-vote fraction、reset回数、version差、flip-back率を含める。時間方向の積分でMを増やさずSNRを得られるかはTDT-Dの中心仮説だが、票の陳腐化とのtrade-offを同時に評価する。

6. 初通過過程の厳密化

6.1 固定長平均

票 $q_t \in \{-1, 0, +1\}$ が固定状態でiid、平均 μ 、分散 σ^2 とする。K票の標本平均 q_K^- について次が成り立つ。

$$\text{Var}(q_K^-) = \sigma^2/K, \text{SNR}_K = |\mu| \sqrt{K}/\sigma$$

これは固定長多数決の評価であり、閾値 $\pm\Theta$ への初通過誤率にはそのまま適用しない。

6.2 iid 3値票のgambler's ruin

命題1 (対称閾値への初通過) $P(q_t=+1)=p_+$ 、 $P(q_t=-1)=p_-$ 、 $P(q_t=0)=p_0$ 、 $p_+ > p_-$ とする。 $C_0=0$ から開始し、 $\tau = \inf\{t: |C_t| = \Theta\}$ とする。正方向を $+\Theta$ とすれば、誤方向初通過確率 ε と平均停止時間は次である。

$$\varepsilon = P(C_\tau = -\Theta) = 1 / [1 + (p_+/p_-)^\Theta]$$

$$E[\tau] = \Theta(1-2\varepsilon)/(p_+-p_-) = \Theta(1-2\varepsilon)/|\mu|$$

証明概略：0票は停止時間だけを遅らせ、非零step列はbiased gambler's ruinである。到達確率は差分方程式から得られる。また $E[C_\tau] = \Theta(1-2\varepsilon)$ と、停止マルチンゲール $C_t - \mu t$ にoptional stoppingを適用して平均時間を得る。高SNRで $\varepsilon \rightarrow 0$ なら $E[\tau] \approx \Theta/|\mu|$ となる。

例として $p_+=0.55$ 、 $p_-=0.45$ 、 $p_0=0$ なら $\mu=0.1$ である。 $\varepsilon=0.01$ を満たす閾値は

$$\Theta \geq \log(99)/\log(0.55/0.45) = 22.9\dots, \text{したがって } \Theta = 23$$

小ドリフトの拡散近似では $\varepsilon \approx \exp(-2|\mu|\Theta/\sigma^2)$ となる。一般の有界増分ではmgfから指数マルチンゲールを構成し、相関・非定常票ではiid式を適用せず、block bootstrapまたはmixing仮定に基づいて実測する。

実験仮説 H1 (C8 sufficiency)

単純iidモデルでは $\Theta \ll 127$ で1%誤率を満たし得るため、INT8は有望である。ただし実票の自己相関、ゼロ率、scale drift、リーク、reset、飽和、stalenessにより必要rangeは変わる。C8/C16を比較し、誤方向発火率、平均待ち時間、飽和率、stale fractionを同時に測定して採否を決める。

7. 1スカラー測定からの離散行動識別

7.1 局所遷移場と情報制約

固定状態近傍の有向辺価値を並べたベクトルを $d(T, \alpha) \in \mathbb{R}^E$ とし、候補対の辺incidenceを $\phi(u)$ とする。局所加法近似の下では1候補対から得る情報は次の1本のスカラー測定である。

$$y_t = d^T \phi(u_t) + \eta_{\text{int},t} + \varepsilon_{\text{data},t}$$

d がdenseで独立なE自由度を持つなら、 $M \ll E$ の測定から各辺の最適行動を一般に識別できない。これは単に推定器分散の問題ではなく、観測数に対する識別可能性の問題である。ゼロ次最適化の次元依存下界 [9,10] と、疎・低次元構造がある場合に少数測定から復元できる圧縮センシングの結果 [11] は、この境界を理解する参照点になる。ただし、それらの連続・線形理論をTDT-Dへ直接適用したとは主張しない。

中心仮説 H2（低実効次元の局所遷移場）

学習中の局所遷移場 d は、既知または学習可能な基底 U に対して $d \approx U h$, $\text{rank}(U) = d_{\text{eff}} \ll E$ 、あるいは適切な基底で疎・block-correlatedである。この構造が時間的に十分安定し、 $M = O(d_{\text{eff}})$ または疎復元に対応する測定数で、損失を下げる離散行動を識別できる。

7.2 ブロック化の二つの意味

ブロック全体を1変数として同じ行動へ結び付ける場合、探索変数数はブロック数 B になるが、これは $N \rightarrow B$ の無料の次元削減ではなく、許される更新空間を制限している。ブロック内各辺を独立な $\pm$ 方向で摂動する場合、2 forwardで票を共有できるが、識別すべき自由度はactive edge数に残り、SPSA型の相関と分散を負う。両方式を別アルゴリズムとして報告する。

7.3 離散摂動半径と相互作用残差

通常のSPSAは連続摂動幅 c を0へ近づけて高次項を抑えられる。TDT-Dの最小遷移は隣接3値状態間の1段階であり、ブロック内 h 個の辺を同時に横断すれば候補はHamming距離 h だけ離れる。したがって η_{int} を摂動幅縮小で消せない。独立validationで測った単一辺価値から $y_{\text{add},t} = d^T \phi(u_t)$ を構成し、次を測定する。

$$R_{\text{int}} = E[(y_t - y_{\text{add},t})^2] / (E[y_t^2] + \epsilon_{\text{num}})$$

実験仮説 H3（相互作用の制御）

R_{int} がHamming半径 h 、block size、モデル規模に対して許容範囲に保たれる構造化候補対が存在する。 R_{int} が h とともに急増し、action regretも悪化する場合、大規模ブロックTDT-Dを早期棄却する。

8. 発火品質と有限時間ドリフト**8.1 発火品質の指標**

発火イベントに対し、 P_{action} 、 $P_{\text{improve}} = P(\Delta F < 0 | \text{fire})$ 、 $E[\Delta F | \text{fire}]$ 、局所regret R_{local} を測定する。oracle gain magnitude $g_i = -\min_a \Delta_i(a)$ でvery small / small / medium / largeにbinningし、重要な大gain行動での性能を分離する。

命題2（行動正解率と期待降下） 1座標または実際に適用した集合更新を1行動として扱う。発火時に正しい行動を選ぶ確率を p とし、正解時の平均改善が少なくとも $G_+ > 0$ 、不正解時の平均悪化が高々 $G_- \geq 0$ 、すなわち

$$E[\Delta F | \text{correct, fire}] \leq -G_+, E[\Delta F | \text{wrong, fire}] \leq G_-$$

を満たすなら、全期待値の法則により

$$E[\Delta F | \text{fire}] \leq -pG_+ + (1-p)G_-$$

したがって期待降下の十分条件は

$$p > G_- / (G_+ + G_-)$$

である。よって $P_{\text{action}} > 0.5$ は普遍的な合格条件ではない。誤行動のdamageが大きければ、高いaccuracyでも期待損失は増加し得る。実験では p 、 G_+ 、 G_- と $E[\Delta F | \text{fire}]$ を同時推定する。

8.2 停止時刻までの有限時間命題

命題3（first exitまでの発火数） 発火番号 n での状態を w_n 、履歴を H_n とし、領域 A からのfirst exit timeを $\tau_A = \inf\{n: w_n \notin A\}$ とする。 $F \geq F_{\text{inf}}$ であり、 $n < \tau_A$ の間、実際に適用される集合行動の損失差 $\Delta_n = F(w_{n+1}) - F(w_n)$ が

$$E[\Delta_n | H_n] \leq -\gamma, \gamma > 0$$

を満たすなら、任意の有限 m について

$$E[\min(\tau_A, m)] \leq [F(w_0) - F_{\text{inf}}] / \gamma$$

が成り立ち、 $m \rightarrow \infty$ で可積分条件の下 $E[\tau_A] \leq [F(w_0) - F_{\inf}] / \gamma$ を得る。証明は停止過程の条件付きドリフトを望遠和し、 F の下界を用いる。 A を出た後の再入場を含む生涯総発火数にはこのboundを適用しない。本命題は大域収束、局所最適への収束、循環排除を保証しない。

9. 学習則 TDT-D

Algorithm 1 Edge-TDT-D（同期accumulation版）

入力：3値成分 T 、固定または低頻度更新の層scale α 、辺証拠 C 、閾値 Θ 、上限 $C_{\max}$ 、ブロック選択則、epoch長 K 、同時発火上限 k 。

Step 1：weight-versionを固定し、ブロック B と共通seed列を選ぶ。

Step 2：境界整合な候補対 T^+, T と辺incidence ϕ を生成する。

Step 3：同一batchで2 forwardを実行し、 $y = \ell(T^+) - \ell(T)$ を得る。分散data parallelでは各workerの y のみを平均all-reduceする。

Step 4：epoch内固定の S_l で正規化し、共有乱数により $q_e = Q(-y\phi_e / S_l)$ を各workerで同一生成する。

Step 5：現状態に接続する辺の C_e を更新し、age、clip、saturation、stalenessを記録する。

Step 6： K 測定後または閾値到達時、実行可能な辺から較正score最大の行動を選び、最大 k 件を適用する。

Step 7：発火座標の両辺証拠をresetし、versionを進める。必要に応じ同一ブロックまたは依存近傍をresetする。

10. 計算・メモリ帯域・通信モデル

10.1 摂動対数 M とforward-equivalent

forward費を C_F 、backward費を近似的に $2C_F$ と置くと、標準backprop stepは約 $3C_F$ である。独立な摂動対を M 個使うTDT-D測定は $2MC_F$ であり、step費比は次となる。

$$C_{\text{TDT}}/C_{\text{BP}} \approx 2M/3$$

したがって33%削減というproxyは $M=1$ に限る。 $M=2$ では約1.33倍、 $M=4$ では約2.67倍、 $M=8$ では約5.33倍である。 M 台並列化はwall-clockを短縮できるが、FLOPs、GPU-seconds、Jouleを減らさない。独立平均によるSNR改善は $\sqrt{M}$ である。TDT-Dの成立には、 M を増やさず時間方向のaccumulatorで証拠を得ながら、同一到達lossまでの総測定数を抑える必要がある。

10.2 Counter容量とHBM traffic

実用的な2-bit packの3値重みは N パラメータ当たり約 $N/4$ byteである。一方、1個のC8 stateは N byte、2辺を単純保持すれば最大 $2N$ byteとなる。 $N=10^{12}$ では、重み約250 GB、C8 1個で1 TB、2辺で2 TBである。Adamより小さくても、optimizer stateが消えるわけではない。

active edge集合 E_t を毎測定でread+writeする最小trafficは、1-byte counterなら約 $2|E_t|$ byte、2辺同時更新なら最大 $4|B_t|$ byteに達する。全 N を走査する設計では整数加算よりHBM帯域が律速し得る。block-sparse access、bit packing、遅延更新、on-chip tile accumulationを比較し、HBM bytes/tokenとlocal memory trafficを必須指標にする。

表2 総コスト評価で必須の指標

軸	測定量	判定上の注意
計算	forward-equivalent/token、到達lossまでの累積FLOPs	M、再評価、捨てた候補をすべて含む
時間	wall-clock、GPU-seconds	並列Mによる見かけの短縮と総資源を分離
エネルギー	J/token、到達lossまでの総Joule	GPU以外の通信・host費も可能な範囲で含む
容量	peak VRAM/HBM、counter bytes/parameter	重み、scale、counter、forward workspaceを分離
帯域	HBM bytes/token、counter read/write bytes	全走査かblock-sparseかを明記
通信	data-parallel bytes/token、collective回数	gradient同期とscalar差分同期を区別
品質	val loss、perplexity、下流性能	同一token、同一FLOPs、同一時間の3軸で比較

10.3 共通seedによるscalar all-reduce

R個のdata-parallel workerが同一T、C、 α 、S、block schedule、seed u_t を保持する。各worker r はローカルbatchで

$$y_t^{(r)} = \ell_r(T^+) - \ell_r(T^-)$$

だけを計算し、all-reduceするのは

$$y_{\text{bar},t} = (1/R) \sum_{r=1}^R y_t^{(r)}$$

というM個のscalarである。各workerは共通seedから ϕ と確率丸め乱数を再生成し、同一票・同一発火をローカルで再構成する。理想的なdata-parallel同期量はgradient all-reduceのO(N)からO(M) scalar/測定へ下がり得る。ただしdeterminism、失敗worker、scale同期、version driftを厳密に管理する必要がある。またtensor parallel、pipeline parallel、expert routing、forward activation通信は消えないため、通信全体がO(1)になるとは主張しない。

実験仮説 H4（分散通信優位）

共通seed protocolにより、data-parallel optimizer同期をscalar差分へ縮約し、forward内通信を含む総byte/tokenでもbackprop baselineに対する実用的優位を得られる。

11. 段階的検証計画

最終目標はW3/A3だが、原因分離のためA16→A8→A4→A3と進める。BF16モデルは性能・コストの外部参照であり、ネイティブ3値モデルの「真の重み」または量子化誤差の唯一の基準とは扱わない。各stageは前段の停止条件を満たした場合のみ進める。

表3 TDT-v4の段階的実証計画

段階	構成	主要測定と通過条件
A action識別	1-10M、W3/A16、固定状態。独立validationで全合法行動を一部厳密評価	P_action、P_improve、E[$\Delta F fire$]、R_localをgain bin別に測定。95% CIで期待降下が負、damage-adjusted閾値を超える
B 確率過程	C8/C16、 $\Theta=\{8,16,23,32,64,127,256\}$ 、同期/リーク/age制限	gambler's ruinとの差、自己相関、待ち時間、飽和、vote age、stale fraction、boundary lock不在を確認
C 要因分解	10-50M、同一データ・tokenizer・初期化	STE-Adam/SGD、ternary-Bop、plain discrete SPSA、TDT-Dを比較し、counterとevent駆動の寄与を分離
D 構造・識別	block tying / within-block random、Hamming半径とMを掃引	d_eff proxy、R_int、action regret、必要MまたはKの成長を測定。N→Bとは表現しない
E スケール	100M→500M。分散共通seed protocol	同一到達lossのFLOPs、GPU-seconds、J/token、HBM bytes/token、通信byte/tokenが競争的
F 活性化拡張	A16→A8→A4→A3。演算別precisionを明記	各段階の劣化源を分離し、A3 stored activationで安定学習を確認

11.1 Stage Aのoracle設計

サンプル座標 i について、現在値、合法的隣接値、stayの全候補を独立validation batchで評価する。同値許容幅 δ_{tie} を事前登録し、 $|\Delta \text{差}| \leq \delta_{tie}$ は複数正解とする。 P_{action} だけでなく、行動後の実 ΔF 、 R_{local} 、誤行動damageの分布を報告する。very small gainの多数がaccuracyを支配しないよう、gain bin別曲線とgain-weighted regretを主結果にする。

合格条件は $P_{action} > 0.5$ ではない。命題2のdamage-adjusted閾値を下側信頼限界で超え、E[$\Delta F|fire$]の95%信頼区間上端が0未満であることを最小条件とする。 $k > 1$ の場合は集合更新をoracle評価し、単一座標gainの和で代用しない。

11.2 必須baselineとablation

Stage Cは、(i) native ternary forwardを持つSTE-Adam/SGD、(ii) ternaryへ拡張したBop系直接更新、(iii) accumulatorなしで即時離散更新するplain discrete SPSA、(iv) edge accumulatorを持つTDT-Dの4本を最低限比較する。これにより、ゼロ次信号、counter、event駆動、辺表現の寄与を分離する。さらに固定 α と低頻度学習 α 、parameter counterとedge accumulator、MとK、reset/leak/version方式をablationする。

12. 反証条件と限界

TDT-Dの中心仮説は、1 scalar measurementから有用な離散actionを復元できる構造が、実際のTransformer学習中に存在することである。以下のいずれかが再現性をもって観測された場合、現在形のTDT-Dによる低コスト事前学習仮説を棄却または大幅に縮小する。

停止理由	反証観測
識別不能	大gain binでもdamage-adjusted action条件を満たさず、E[$\Delta F fire$] ≥ 0
相互作用支配	R_intがHamming半径とともに急増し、小blockでもaction regretを制御できない
測定数の破綻	必要Mまたは有効Kがd_effやモデル規模に対して急増し、2-forwardの利点を失う
陳腐化	stale-vote fractionを抑えるresetが頻繁すぎ、証拠が閾値へ到達しない
帯域律速	counter HBM bytes/tokenがforward削減を上回り、J/tokenまたはwall-clockが悪化
分散不一致	共通seed protocolでstate divergenceが発生、またはforward通信が支配して優位が消える
低活性化精度	A3への段階移行で安定学習が成立せず、W3/A3目標とTDT-D効果を両立できない

本稿の有限時間命題は、これらの問題を解決しない。非凸・非定常な巨大言語モデルに対する大域収束、定常分布、局所最適到達、最適sample complexityは未確立である。 α 、normalization、attention、residual、データ順序、

分散実装を含むシステム全体の実測が必要である。

13. 結論

TDT-v4は、ネイティブ3値モデルの学習を、離散状態グラフ上のaction selectionとedge evidenceの初通過発火として定式化した。初通過誤率はgambler's ruinにより評価され、単純iid票ではC8範囲内の閾値が十分になり得る。一方、TDT-Dの可否を決める中心問題は、1個のscalar loss differenceから高次元の局所遷移価値をどの条件で識別できるかである。低実効次元、疎性、低ランク、ブロック相関が存在し、離散相互作用と票の陳腐化を制御できるなら、TDT-Dはbackprop保存活性化とdata-parallel gradient同期を大きく削減する可能性を持つ。

最初に判定すべきなのは収束定理ではない。固定状態の小規模モデルで、独立validationに対する P_{action} 、 $E[\Delta F]_{\text{fire}}$ 、 R_{local} 、 R_{int} を測り、damage-adjusted expected descentが成立するかを確認することである。その後、counter精度、時間積分、分散通信、HBM帯域、A3へ段階的に進む。この順序により、肯定結果だけでなく否定結果も、BigTernaryにおける情報効率の境界として解釈できる。

参考文献

- [1] Ma, S., Wang, H., Ma, L., Wang, L., Wang, W., Huang, S., Dong, L., Wang, R., Xue, J., & Wei, F. (2024). The Era of 1-bit LLMs: All Large Language Models are in 1.58 Bits. arXiv:2402.17764. <https://arxiv.org/abs/2402.17764>
- [2] Wang, H., Ma, S., & Wei, F. (2024). BitNet a4.8: 4-bit Activations for 1-bit LLMs. arXiv:2411.04965. <https://arxiv.org/abs/2411.04965>
- [3] Wang, H., Ma, S., & Wei, F. (2025). BitNet v2: Native 4-bit Activations with Hadamard Transformation for 1-bit LLMs. arXiv:2504.18415. <https://arxiv.org/abs/2504.18415>
- [4] Helwegen, K., Widdicombe, J., Geiger, L., Liu, Z., Cheng, K.-T., & Nusselder, R. (2019). Latent Weights Do Not Exist: Rethinking Binarized Neural Network Optimization. Advances in Neural Information Processing Systems 32, 7533-7544. <https://proceedings.neurips.cc/paper/2019/hash/9ca8c9b0996bbf05ae7753d34667a6fd-Abstract.html>
- [5] Wen, W., Xu, C., Yan, F., Wu, C., Wang, Y., Chen, Y., & Li, H. (2017). TernGrad: Ternary Gradients to Reduce Communication in Distributed Deep Learning. Advances in Neural Information Processing Systems 30, 1509-1519. <https://proceedings.neurips.cc/paper/6749-terngrad-ternary-gradients-to-reduce-communication-in-distributed-deep-learning>
- [6] Wu, S., Li, G., Chen, F., & Shi, L. (2018). Training and Inference with Integers in Deep Neural Networks. International Conference on Learning Representations. <https://openreview.net/forum?id=HJGXzmspb>
- [7] Spall, J. C. (1992). Multivariate Stochastic Approximation Using a Simultaneous Perturbation Gradient Approximation. IEEE Transactions on Automatic Control, 37(3), 332-341. <https://doi.org/10.1109/9.119632>
- [8] Malladi, S., Gao, T., Nichani, E., Damian, A., Lee, J. D., Chen, D., & Arora, S. (2023). Fine-Tuning Language Models with Just Forward Passes. Advances in Neural Information Processing Systems 36. <https://doi.org/10.52202/075280-2308>
- [9] Duchi, J. C., Jordan, M. I., Wainwright, M. J., & Wibisono, A. (2015). Optimal Rates for Zero-Order Convex Optimization: The Power of Two Function Evaluations. IEEE Transactions on Information Theory, 61(5), 2788-2806. <https://doi.org/10.1109/TIT.2015.2409256>
- [10] Shamir, O. (2013). On the Complexity of Bandit and Derivative-Free Stochastic Convex Optimization. Proceedings of Machine Learning Research, 30, 3-24. <https://proceedings.mlr.press/v30/Shamir13.html>
- [11] Donoho, D. L. (2006). Compressed Sensing. IEEE Transactions on Information Theory, 52(4), 1289-1306. <https://doi.org/10.1109/TIT.2006.871582>
- [12] Feller, W. (1968). An Introduction to Probability Theory and Its Applications, Vol. 1, 3rd ed. Wiley. (biased gambler's ruin の標準結果)
- [13] Xi, H., Chen, Y., Zhao, K., Teh, K. J., Chen, J., & Zhu, J. (2024). Jetfire: Efficient and Accurate Transformer Pretraining with INT8 Data Flow and Per-Block Quantization. Proceedings of Machine Learning Research, 235, 54049-54063. <https://proceedings.mlr.press/v235/xi24b.html>

文書の位置づけ

本稿は理論・アルゴリズム・実験計画を統合した技術論文であり、実験結果を報告するものではない。すべての性能・コスト優位は、表3の段階的検証を通過するまで未確認である。